

머신러닝과 금융: 머신러닝 기반 신용평가모형

디지털추진부

권황현 연구위원(hkwon@kdb.co.kr)

I. 머리말

III. 머신러닝 기반 기업신용평가모형

II. 인공지능, 머신러닝, 그리고 딥러닝

IV. 맺음말

머신러닝은 인공지능의 한 형태로서 2010년대 딥러닝 혁명으로 인해 다시금 주목받고 있는 분야이다. 기존의 컴퓨터 프로그래밍이 어떤 규칙을 알고리즘화하고 데이터 입력을 통해 결과를 도출하는 것이었다면, 머신러닝은 입력 데이터와 결과 데이터에 대한 학습을 통해 규칙을 도출해내는 과정으로서 데이터에 기초한 의사결정에 있어 핵심 요소라 할 수 있다.

그 중에서도 딥러닝은 많은 층으로 이루어진 신경망 구조에 기초하여 입력 데이터의 표현(representation)을 문제해결에 적합한 형태로 변환함으로써, 이미지, 음성, 텍스트 등 지각 데이터에 대한 머신러닝에 있어 인간과 유사한 수준에 도달해가고 있다. 한편, 구조화되어 있는 많은 수의 정형 데이터들에 대해서는 결정 트리(decision tree) 기반의 머신러닝 알고리즘들이 높은 퍼포먼스를 보이며 유용하게 사용되고 있다.

금융권에서도 데이터 기반의 분석과 이에 기초한 비즈니스 인사이트 도출이 그 어느 때보다 중요하게 여겨지고 있으며, 머신러닝은 이러한 과정에 필수불가결한 요소이다. 이에 은행 신용공여에 있어 핵심 중 하나인 신용평가모형에 머신러닝을 적용하는 방안을 논해 보고자 한다. 인간의 자의적 판단을 배제하고 머신러닝을 통해 데이터에 내재된 패턴을 도출함으로써, 기존 모형에 반영되기 어려웠던 비선형적 특징들을 반영할 수 있을 것이며 이는 곧 머신러닝 모형의 변별력을 높이는 데 기여할 것으로 여겨진다.

한편, 의료산업이나 금융업 등 고객 신뢰가 중요한 분야는 모형으로부터 나온 결과를 설명할 수 있어야 하는 바, 머신러닝 모형의 주요한 해결과제 중 하나인 설명력 이슈에 대한 연구 동향을 지켜 볼 필요가 있을 것으로 판단된다.

* 본고의 내용은 집필자의 견해로 당행의 공식입장이 아님

I. 머리말

지난 해 영국은 2021년부터 유통되는 새 50 파운드 지폐의 초상인물로 앨런 튜링(1912~1954)을 선정했다. 그가 동성애로 기소된 지 60여년이 지난 2013년에 사면을 받은 후 새로운 지폐의 초상인물로 선정됨으로써, 너무도 늦었지만 그의 명예회복과 함께 20세기 최고의 지성 중 한 사람으로서의 그의 지위가 확인된 것이라 하겠다. 영화 ‘이미테이션 게임’을 통해 잘 알려졌다듯이 그는 제2차 세계대전 당시 독일군의 암호 ‘이니그마’를 해독하는 장치를 개발해 연합군의 승전에 기여하였다. 하지만 그가 인류에게 더욱 크게 기여한 것은 탁월한 수학자로서 지금도 우리 삶에 큰 영향을 미치는 업적을 남겼고, 컴퓨터과학과 인공지능(Artificial Intelligence, AI)의 아버지로서 두 분야의 토대를 닦은 점일 것이다.

그의 1950년 논문 ‘Computing Machinery and Intelligence’의 첫 문장은 다음과 같은 질문을 생각해 볼 것을 제안하고 있다¹⁾,

“Can machines think?”.

‘인공지능’이라는 분야는 튜링의 이 질문에서부터 시작되었다고 해도 과언이 아닐 것이며, 이 질문에 답하고자 지금도 많은 연구자들이 노력하고 있다. 본고는 이러한 노력들이 현재 어느 지점까지 왔는지 살펴보고, 신용평가모형 등 금융에서의 인공지능 적용 방안들에 대해 논하고자 한다.

사실 현재 인공지능이라는 단어는 전문 영역을 넘어서서 사람들의 상상력을 자극하며 가전, 교육, 금융, 자동차 등 거의 모든 영역에서 마치 만능의 해결사처럼 쓰이고 있다. ‘인공지능’과 함께 혼용되고 있는 단어로는 ‘머신러닝’과 ‘딥러닝’이 있을 것이다. 먼저 II장에서 이렇게 혼용되고 있는 용어들의 의미와 상호관계를 정리하고 인공지능이 지금과 같은 각광을 받게 된 계기에 대해 간략히 서술하고자 한다. 그리고 III장에서는 신용평가모형을 비롯한 금융 분야에서의 인공지능 활용사례에 대해 다루고, 마지막 IV장에서는 인공지능 분야가 해결해야 될 이슈들과 앞으로의 방향에 대해 생각해 보고자 한다.

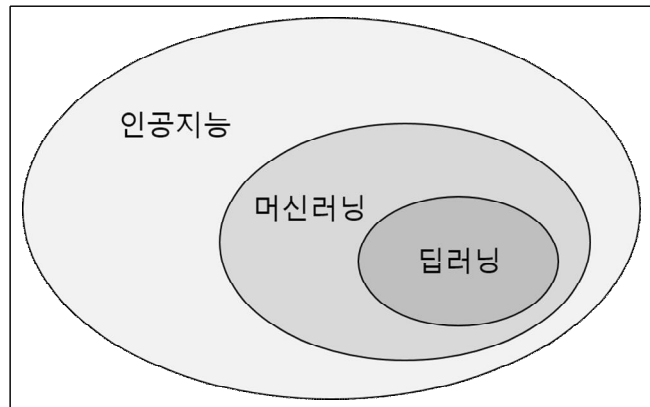
1) Alan Turing(1950), “Computing Machinery and Intelligence”, Mind, 59, pp.433-460.

Ⅱ. 인공지능, 머신러닝, 그리고 딥러닝

1. 인공지능

인공지능, 머신러닝, 딥러닝, 이 세 단어의 관계는 <그림 1>과 같이 표현할 수 있고, 이 중 인공지능은 가장 포괄적인 표현으로서 인간의 지능이 기계에 구현된 것을 뜻하며, 인간의 지적 활동을 컴퓨터 등을 통해 자동화하고자 하는 노력들을 의미하기도 한다.

<그림 1> 인공지능, 머신러닝, 딥러닝의 상호관계



다만, 인공지능은 머신러닝 뿐만 아니라 정해진 규칙을 코딩하여 만들어진 프로그램도 포함한다. 사실 상당기간 인공지능 전문가들은 매우 방대하고 복잡할지언정 이러한 규칙들을 프로그래머들이 코딩함으로써 인간 수준의 지능은 구현 가능할 것으로 믿어왔다. 이러한 접근법을 상징 인공지능 (Symbolic AI)이라 부르며, 1980년대까지 인공지능 학계의 주요 패러다임이었다.

상징 인공지능은 체스 경기처럼 잘 정의된 규칙이 있고 논리적인 과제에는 적합하였으나, 이미지 인식, 음성 인식, 번역 등 복잡하고 모호한 측면이 있는 과제에서는 명확한 규칙을 도출하는 것이 어려움에 따라 한계를 드러냈다.

2. 머신러닝(Machine Learning)

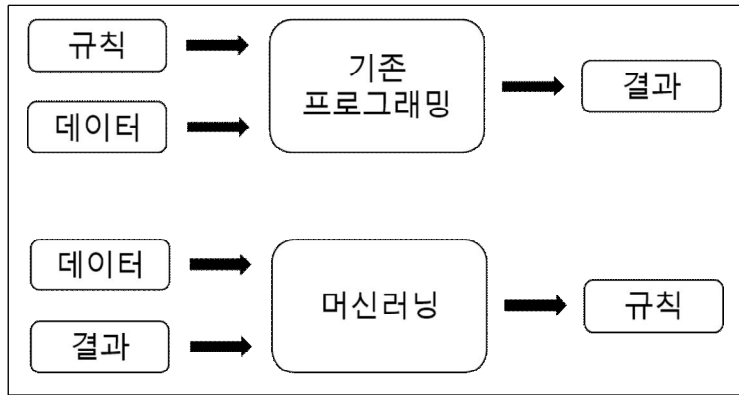
머신러닝은 인공지능의 한 종류로서 정해진 규칙을 컴퓨터에 프로그래밍하는 것이 아니라 주어진 데이터를 컴퓨터가 스스로 학습함으로써 규칙을 도출하고 특정 과제를 수행할 수 있도록 하는 것이다. 기존의 컴퓨터 프로그래밍은 주어진 문제를 해결하는 논리로서의 알고리즘을 고안하여 프로그래밍 언어로 구현하는 것이었다면, 머신러닝은 주어진 문제를 해결하기 위해 관련 데이터를 학습하는 알고리즘을 통해 규칙을 이끌어내는 프로그래밍이라고 할 수 있으며 이를 도식화하면 <그

림 2>와 같다.

머신러닝은 마치 인간이 다양한 경험을 통해 어떤 상황에 대해 인지할 수 있는 능력을 갖게 되는 것처럼, 입력값과 결과값으로 구성된²⁾ 다수의 데이터셋에 대한 학습을 통해 그러한 결과를 이끌어내는 룰 또는 패턴을 발견해가는 과정이다.

<그림 2>

머신러닝 개념도



기존 프로그래밍과의 차이점을 좀 더 자세히 살펴보면 다음과 같다. 먼저 머신러닝 알고리즘을 실행하기 위해서는 아래 세 가지 요소가 필요하다.

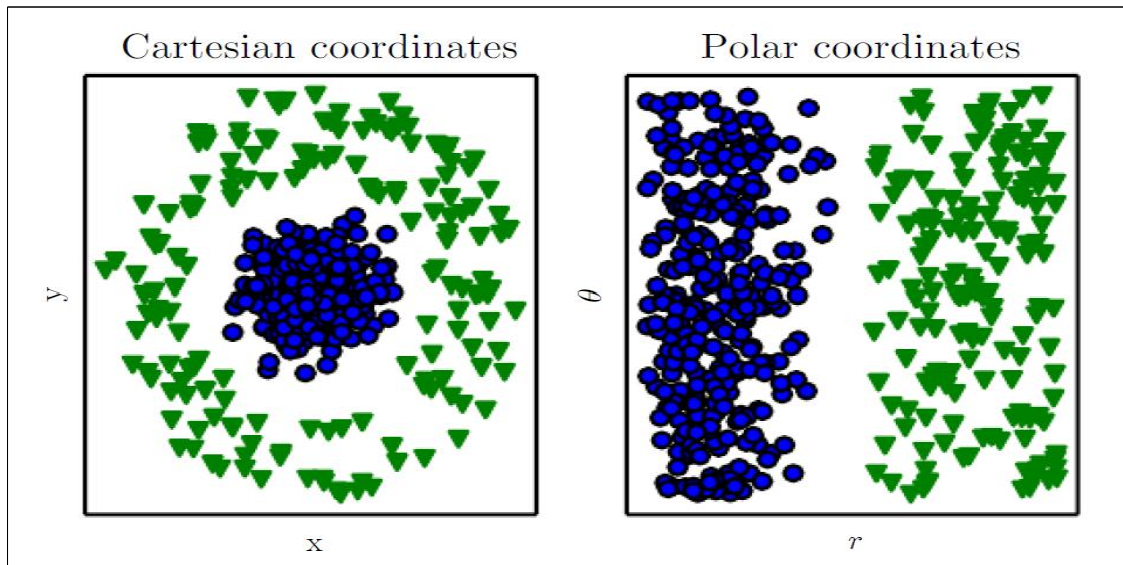
- ① 입력값: 학습시키고자 하는 과제의 데이터 input으로서 예를 들어, 이미지 인식을 학습시키고자 하는 경우에는 이미지 데이터, 번역 머신러닝 엔진을 위해서는 번역 대상인 언어의 텍스트 데이터 등이 된다.
- ② 결과값: 학습시키고자 하는 과제의 데이터 output으로서 상기 예시에 있어, 이미지 인식 과제의 경우에는 ‘고양이’, ‘개’ 등 이미지 태그들이며 번역의 경우에는 번역 결과물 언어의 텍스트 데이터가 된다.
- ③ 측정기준: 데이터 입력값과 결과값으로 학습시켜 가는 과정에서 중간단계의 output이 원하는 결과에 얼마나 근접했는지를 측정하는 기준을 뜻하며, 여러 가지 기준 중 과제의 특성 및 도출하고자 하는 목적에 따라 선택할 수 있다. 이러한 측정기준에 기초하여 결과에 근접한 정도를 측정하고, 그 측정값을 피드백 받아 머신러닝 알고리즘의 작동을 매 단계마다 미세조정하는 과정이 바로 우리가 머신러닝을 말할 때 ‘러닝’에 해당하는 과정이다.

우리는 이러한 학습을 거쳐 구축된 머신러닝 모형을 통해 주어진 입력 데이터로부터 유의미한 결과를 얻게 된다. 입력 데이터로부터 머신러닝을 통해 결과물을

2) 머신러닝에는 입력값들만으로 구성된 데이터셋에 대한 학습인 unsupervised machine learning도 있으나, 본고에서는 다수의 머신러닝 프로젝트에 해당하는, 입력값과 결과값으로 구성된 데이터셋에 대한 학습인 supervised machine learning에 대해 다루고자 한다. 기존 컴퓨터 프로그래밍과의 차이점에 있어서는 supervised machine learning과 unsupervised machine learning 모두 동일하다.

도출하는 과정은 일련의 변환 과정으로 볼 수 있으며, 머신러닝에서 데이터를 학습한다는 것은 입력 데이터가 가지고 있는 ‘표현’(representation) 결과를 도출하는데 유용한 방식의 표현을 찾아가는 과정이다. <그림 3>³⁾은 이러한 과정의 한 예시로서, 만약 녹색과 청색의 데이터들을 하나의 직선으로 구별해내고자 할 경우, 왼

<그림 3> 상이한 표현의 예시



쪽의 직교 좌표계 기준의 표현으로는 이는 불가능하고 오른쪽의 극좌표로 표현하였을 때에 가능해짐을 알 수 있다. 따라서 왼쪽과 같이 표현된 입력 데이터를 오른쪽과 같이 극좌표 기준의 데이터로 변환하여 표현한 후, 주어진 과제, 즉, 하나의 직선으로 두 데이터군을 구별하기를 해결할 수 있게 된다.

이렇게 주어진 과제 해결에 좀 더 적합한 표현을 찾아가는 과정을 컴퓨터가 알고리즘을 통해 자동으로 수행하는 것이 바로 머신러닝이다. 이러한 방법론은 여러 가지 문제에 보편적이며 일괄적으로 적용하기 적합한 프레임워크를 갖고 있으며, 데이터 분석을 위한 기존의 통계적 모형 대비 데이터 처리 및 중간단계에서의 여러 통계적 분석을 대폭 줄일 수 있어 모형 구축 과정과 시간을 단축시키면서도 좋은 퍼포먼스를 가져올 수 있는 장점이 있다. 그리고 이러한 머신러닝 수행 과정에 있어 잘 정제된 데이터는 그 무엇보다 중요하다고 할 수 있을 것이다.

3) Ian Goodfellow et al.(2017), “Deep Learning”, MIT Press


3. 딥러닝(Deep Learning)

딥러닝은 머신러닝 중의 하나로서, 입력 데이터로부터 문제 해결에 적합한 표현을 찾는 데 있어 여러 개의 순차적인 표현 층(layer)을 통해 점진적으로 최적의 표현을 찾아가는 방법론과 이러한 방법론을 연구하는 분야를 뜻한다. 딥러닝의 근간이 되는 모형 구조인 신경망(neural network) 기반의 머신러닝 연구는 1950년대부터 있어 왔으나 여러 기술적 제약으로 인해 1990년대에는 소수의 연구자들만이 신경망 기반의 머신러닝 분야를 연구하고 있었다. 이러한 상황은 2010년을 전후하여 Geoffrey Hinton, Yoshua Bengio, Yann LeCun 등의 학자들이 딥러닝 기반의 모형으로 이미지 인식 등의 과제에서 획기적인 성과를 거둠에 따라 학계 및 산업계에 폭발적인 관심을 불러 일으키게 되었다.

딥러닝의 모형 구조를 이루는 신경망은 신경생물학의 용어를 차용하였고 인간 뇌에서의 신경망 구조에 영감을 받았다고는 할 수 있으나, 딥러닝 모형의 메카니즘은 뇌 작동의 그것과는 아무 연관성이 없다. 딥러닝과 그 구조를 이루는 신경망은 주어진 데이터로부터 문제 해결을 위한 최적의 표현을 학습하기 위한 수학적 틀이라고 여기는 것이 적절할 것이다.

<그림 4>

신경망 구조



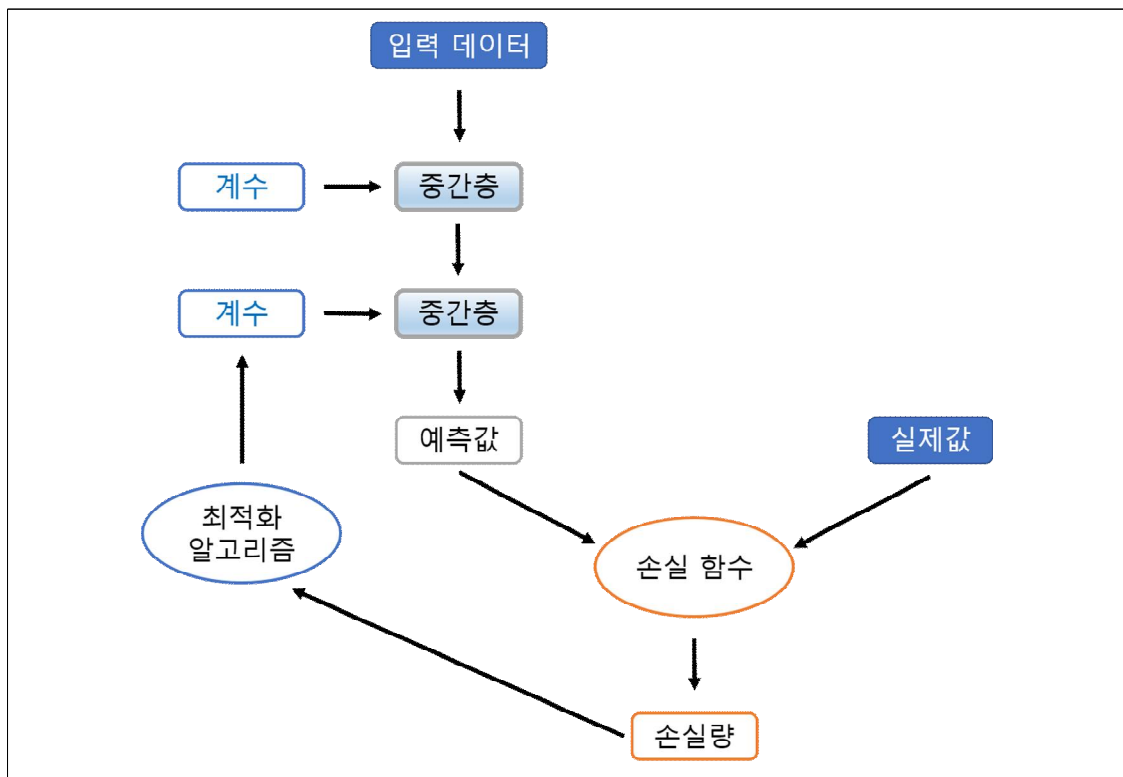
신경망 구조는 <그림 4>와 같은 형태를 띄며, 여기서 세 개의 오렌지색 원은 하나의 입력층, 파란색 원은 출력층, 그리고 녹색 원들은 다섯 개가 하나의 층을 구성하며 여러 개의 중간층을 나타낸다. 각각의 원들은 노드(node)라 불리며 데이터

의 특성을 나타내는 요소라 볼 수 있다. 그리고 복잡하게 얽힌 선들은 여러 층의 노드들 간의 네트워크를 뜻한다. ‘딥러닝’에서 ‘딥’의 의미는 신경망 구조에서 중간층이 여러 개로 구성되어 있다는 의미이며 현대 머신러닝 모형은 중간층이 수십에서 수백개까지 구성되는 경우도 있다.

이렇게 구성된 신경망 위에서 딥러닝은 어떤 과정을 통해 학습이 이루어지는 것일까? 이에 대한 답을 아래 그림을 통해 개략적으로 설명하고자 한다.

<그림 5>

딥러닝 학습 개념도



딥러닝 모형을 구성하고 있는 중간층은 수학적 변환을 나타내며 이는 변환함수의 계수(weight)를 통해 구체적으로 특정된다. 딥러닝 모형은 학습을 통해 특정 계수의 조합을 찾음으로써 완성된다. 먼저 모형은 임의의 값을 계수 초기값으로 설정한 다음, 다수의 입력 데이터셋을 이 계수들로 특정된 중간층 변환을 거치게 한 후 예측값을 도출하게 된다. 이렇게 도출한 입력 데이터별 예측값과 각각의 입력 데이터에 해당하는 실제 결과값이 얼마나 가까운 지를 측정하는 기준을 수학적으

로는 손실함수로 나타내며 그 값, 즉, 손실량은 최적화 알고리즘을 통해 손실함수의 최소값을 찾는 방향으로 계수를 조정하는 피드백의 역할을 하게 된다. 그렇게 조정된 계수로 구성된 중간층에 다시 입력 데이터를 투입하여 손실량을 계산하고 그 값으로 다시 계수를 조정하는 과정을 반복한다. 이렇게 손실함수 최소화를 위해 계수를 조정해 가는 과정은 딥러닝의 핵심으로서 Back-propagation이라 불린다.

앞서 우리는 머신러닝이 통계적 모형보다 그 적용에 있어 보편적이고 일괄적으로 적용하기 수월한 프레임워크를 갖고 있음을 기술한 바 있다. 그러나 이미지, 음성, 텍스트 등 인지적 데이터에 대해서는 딥러닝 이전의 기존 머신러닝 또한 소위 말하는 피처 엔지니어링(feature engineering)을 통해 알고리즘 입력 데이터로 적정한 데이터 특징(feature)을 추출하는 작업을 별도로 해주어야 했다. 딥러닝은 다층적 신경망 구조를 통해 데이터를 최적의 표현으로 변환해주는 과정이 자동화되어 있는 바, 이러한 피처 엔지니어링 작업이 불필요해짐에 따라 인지적 데이터에 대한 머신러닝 학습 과정이 획기적으로 간소화되었다.

딥러닝은 2010년대 들어 기존의 머신러닝이 해결하기 어려웠던 여러 과제들에 대해 딥러닝 혁명으로 불릴 만큼의 탁월한 성과를 거두게 되며 다음은 그 몇가지 사례이다.

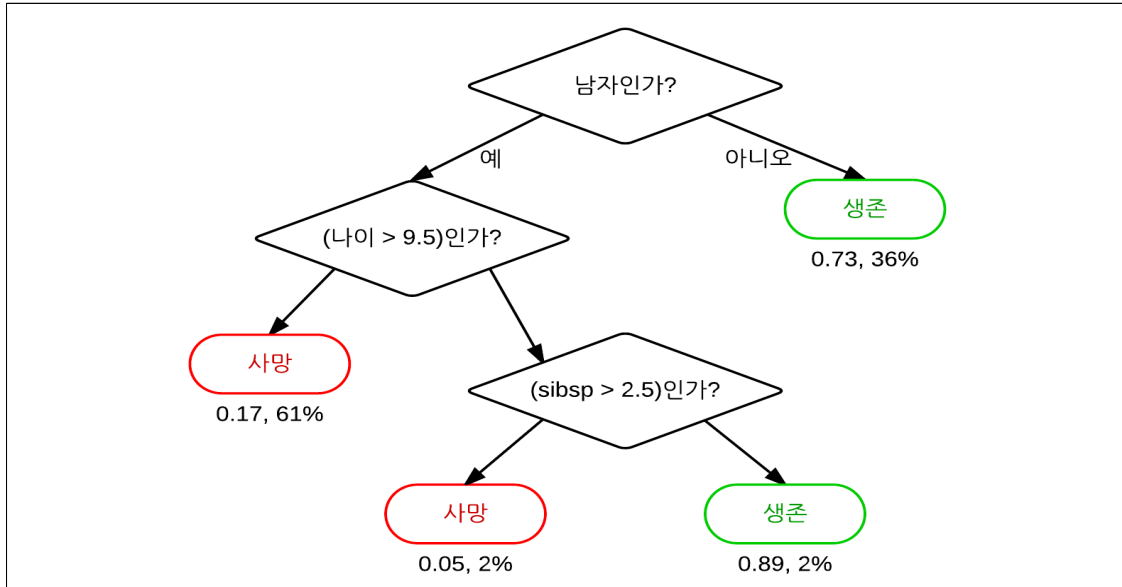
- 인간 수준의 이미지 인식: IMAGENET 오류율에서는 인간 추월
- 인간 수준의 음성 인식: 인간 수준의 단어오류율 WER 기록
- 현저히 개선된 문장 이해력: 언어이해도 벤치마크 GLUE에서 일반인 추월
- 바둑 시합에서 인간에 대해 승리

딥러닝을 중심으로 머신러닝은 놀라운 발전을 이루었지만 근본적으로는 데이터로부터 패턴을 인지하는 방식에 기초하고 있는 바, 인간처럼 경험하지 못한 상황에 대한 추론 등을 포함한 인간 지능을 구현하는 general intelligence와는 거리가 있다. General intelligence를 구현하기 위한 여러 노력들이 시도되고 있으나 아직 가시적 성과가 있지는 않은 것으로 사료된다.

한편, 실무적으로 활용되고 있는 머신러닝 알고리즘을 살펴보면 지각(perceptual) 데이터에 대한 머신러닝은 딥러닝 알고리즘을 사용하고 비지각(nonperceptual) 데이터 및 숫자 테이블 등 구조화된 데이터에 대한 머신러닝에서는 decision tree 기반의 random forest 또는 gradient boosting machine 알고리즘이 많이 활용된다. 특히, gradient boosting machine은 <그림 6>⁴⁾의 decision tree를 반복적으로 적용

하는 알고리즘으로서 전 단계 tree에서 예측력이 낮았던 요소들에 대한 학습을 강화하는 방식으로 모형 개선을 이루는 방법론이며 구조화된 데이터에 대한 머신러닝에 있어 상당히 우수한 알고리즘으로 알려져 있다.

<그림 6> 타이타닉호 탑승객의 생존여부를 나타내는 결정트리



주 : sibsp는 탑승한 배우자와 자녀 수를 의미하며, 옆 아래의 숫자는 각각 생존확률과 탑승객이 그 앞에 해당할 확률을 의미함

Ⅲ. 머신러닝 기반 기업신용평가모형


1. 기업신용평가모형

기업신용평가는 은행이 차주에게 신용을 공여함으로써 발생하는 리스크의 관리를 위해 차주의 채무상환능력을 평가하여 등급화하는 업무로서, 은행 리스크 관리에 있어 핵심업무 중 하나이다. 이러한 평가는 통상 차주의 재무 정보에 기초한 ‘재무평가’와 경영능력 등 계량화하기 힘든 비재무적 요소에 대한 ‘비재무평가’로 나뉘어지며, <그림 7>과 같은 절차로 이루어진다.

4) 위키피디아 페이지, https://ko.wikipedia.org/wiki/결정_트리_학습법, 참고

<그림 7>

신용평가 절차



위의 그림에서 ‘필터링’은 발생빈도는 낮으나 채무상환능력에 주요한 영향을 미치는 사유에 해당하는 기업의 등급을 특정등급으로 하향하는 과정이며, ‘등급조정’은 적정 사유가 있는 경우 평가자가 등급을 조정하는 단계이다.

기업신용평가모형은 기업의 재무·비재무 정보로부터 채무상환능력을 계량화하는 모형으로서 <그림 7>의 ‘신용평가 절차’에서 재무평가, 비재무평가, 그리고 필터링까지의 과정이 모형 하에서 이루어지며 이를 통해 산출된 등급을 모형등급이라 한다. 신용평가모형의 구축은 기업 재무 데이터와 부도의 관계에 대한 통계적 분석, 평가자의 전문가 판단 등을 반영하여 이루어지며, 이러한 과정에서 담당자의 판단 등 인간에 의한 개입이 적지 않게 발생하게 된다.

2. 머신러닝 기반 신용평가모형

머신러닝이란 주어진 룰에 입력값을 투입하여 결과를 도출하는 기존의 알고리즘이 아니라, 주어진 데이터로부터 룰을 도출하는 알고리즘이라 할 수 있다. 딥러닝을 비롯한 머신러닝의 금융 적용사례 중 대표적인 것 중의 하나는 신용평가모형일 것이다. 본고에서는 그 중에서 먼저 신용평가 재무모형에 대해 방법론상 개념적 측면에서 다루고자 한다. 기존의 신용평가 재무모형은 평가항목을 입력변수로 하여 주로 로지스틱 회귀 모형으로 개발되어 왔다. 그 과정에서 다양한 통계적 분석 및 의사결정을 통해 전체 후보 평가항목 중 일부를 선정한 후 로지스틱 회귀분석에 들어가게 된다. 이러한 방식은 예상부도율과 평가항목 사이에 특정한 수리적 관계를 가정하는 셈이 되며 데이터에 내재된 특성을 충분히 반영하고 있다고 하기 어렵다.

이에 데이터 기반의 머신러닝 기법을 도입함으로써 신용평가모형의 고도화를 도모할 수 있을 것으로 판단된다. 현재 머신러닝 알고리즘은 크게 신경망 기반의 알

고리즘과 그에 속하지 않는 알고리즘으로 나눌 수 있을 것이다. 머신러닝 기반 신용평가 재무모형은 재무 정보(입력 데이터)와 부도여부(결과 데이터) 간의 관계를 머신러닝을 통해 모델링하는 것으로 지도학습(Supervised Learning)에 해당하며, 구조화된 데이터들인 바 Decision Tree 기반의 Gradient Boosting Machine(GBM) 알고리즘을 검토하고자 한다.

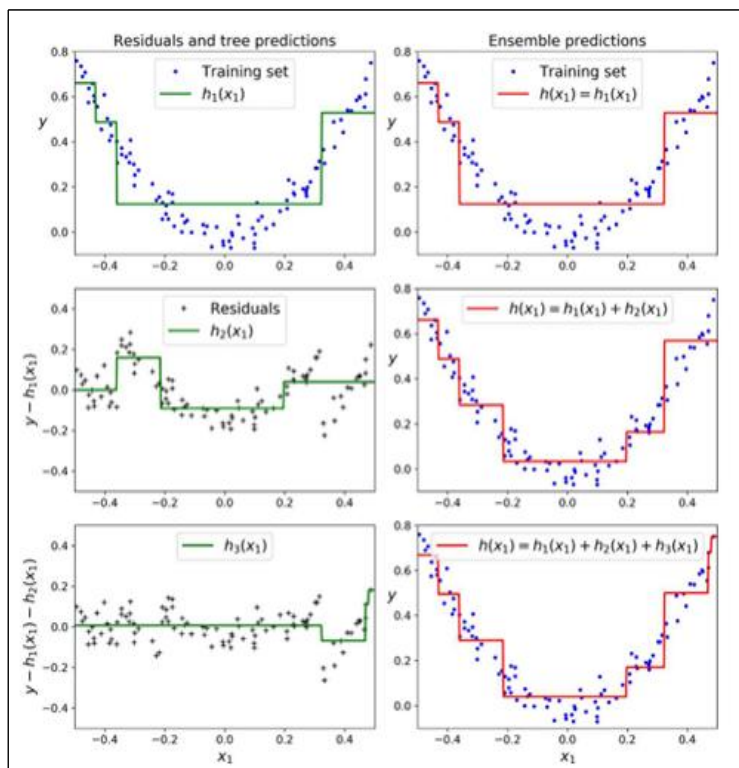
GBM은 오른쪽 <그림 8>과 같이 전 단계 tree의 예상결과와 실제 결과의 차이를 다음 tree의 손실 함수로 정의하는 방식으로 순차적으로 tree를 구성한 후, 이들 각각의 tree의 예측결과를 합산하는 ensemble 방식의 모형이다. GBM 방식의 알고리즘은 잔여 예러가 큰 데이터셋에 좀 더 주안점을 두고 학습을 진행하므로 트레이닝 결과가 우수하다.

신용평가모형은 머신러닝 관점에서는 이진 분류(binary classification) 문

제로서 머신러닝 결과를 측정하는 주요한 metric으로는 정확도와 ROC (Receiver Operator Characteristic) 커브에서 AUC(Area Under the Curve)⁵⁾가 있다. 신용평가모형의 경우 부도 사례가 정상 사례보다 샘플 수가 훨씬 작음에 따라 정확도보다는 AUC를 metric으로 사용하는 것이 적절한 것으로 판단된다.

<그림 8>

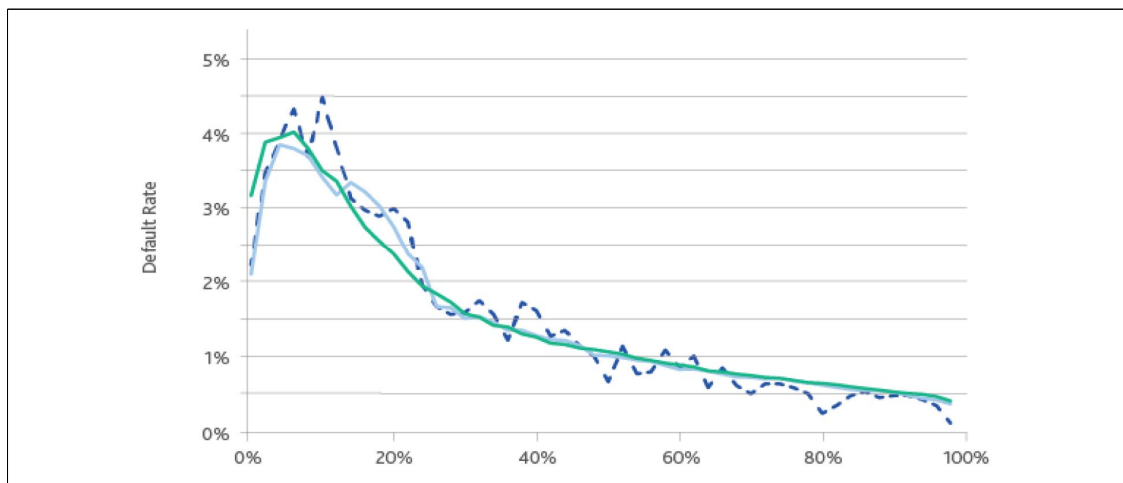
GBM 개념도



5) Gunter Loeffler et al.(2011), "Credit Risk Modeling using Excel and VBA", Wiley

이러한 과정을 통해서 구축한 머신러닝 신용평가모형은 대개 모형 변별력이 우수하고 신용평가에 있어 비선형적 요소를 잘 반영하는 것으로 보고되고 있다. 한 사례로 Moody's의 연구결과를⁶⁾ 예로 들자면, boosting 기반의 머신러닝 모형이 가장 우수한 변별력을 보여주며 <그림 9>와 같이 이자비용 대비 EBITDA 비율과 부도율 간의 비선형적 요소도 가장 잘 반영하고 있음을 확인할 수 있다.

<그림 9> 부도율 vs 이자비용 대비 EBITDA 비율



주 : 점선은 실제 부도율, 녹색은 기존 모형, 하늘색은 boosting 모형

머신러닝 신용평가모형은 여러 가지 긍정적인 면이 있으나, 향후 해결해야 할 이슈 중의 하나는 설명력의 문제이다. 의료나 금융 분야에서는 고객 또는 현업 담당자들에게 모형의 결과를 설명할 수 있는 것이 중요한데, 현재 머신러닝 모형들은 이 점에 있어 명확한 결론이 없는 것으로 판단된다. 다만, 이는 머신러닝 적용 신용평가모형 뿐만 아니라 머신러닝의 보편적 이슈인 바, 머신러닝 분야에서 활발히 연구되고 있다.

6) Dinesh Bacham, et al.(2017), "Machine Learning: Challenges, Lessons, and Opportunities in Credit Risk Modeling", Moody's Analytics Risk Perspective, Vol. IX

IV. 맺음말

현대 인간의 삶에서 머신러닝은 다양한 영역에서 영향을 미치고 있으며, 금융에서도 데이터 기반의 의사결정을 위한 시도들이 많이 이루어지고 있다. 머신러닝 신용평가모형은 그러한 시도들 가운데 대표적인 사례 중 하나로서, 학계 및 금융계의 다수의 자료에서 그 효용성이 입증되고 있다고 할 수 있을 것이다. 머신러닝이 해결해야 하는 과제 중 하나인 설명력을 갖춘다면, 머신러닝 기반 신용평가모형은 유효한 모형으로 자리잡을 수 있을 것으로 판단된다.

참고문헌

[영문자료]

Alan Turing(1950), “Computing Machinery and Intelligence”, Mind, 59, pp.433-460.

Dinesh Bacham et al.(2017), “Machine Learning: Challenges, Lessons, and Opportunities in Credit Risk Modeling”, Moody’s Analytics Risk Perspective, Vol. IX

Gunter Loeffler et al.(2011), “Credit Risk Modeling using Excel and VBA”, Wiley

Ian Goodfellow et al.(2017), “Deep Learning”, MIT Press

Yann LeCun, Yoshua Bengio, and Geoffrey Hinton(2015), “Deep learning”, Nature 521, pp. 436-444

[인터넷 자료]

https://ko.wikipedia.org/wiki/결정_트리_학습법